DDPM：从噪声到图像

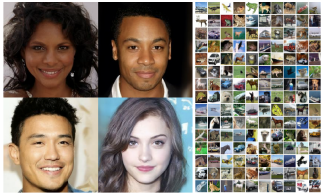
Denoising Diffusion Probabilistic Models

Jonathan Ho / Ajay Jain / Pieter Abbeel

论文精读汇报 | NeurIPS 2020

汇报人：尚运鹏

01 学习图像分布



希望学到 $p_\theta(x_0) \approx p_{\text{data}}(x_0)$。对独立训练样本，最大化似然等价于最大化对数似然：

$$\theta^* = \arg\max_\theta \sum_{i=1}^{N} \log p_\theta(x_0^{(i)}).$$

所以最小化

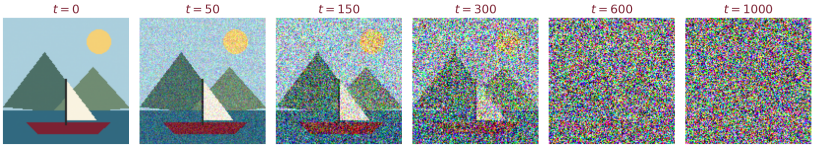
$$\mathcal{L}_{\text{NLL}} = -\sum_{i=1}^{N} \log p_\theta(x_0^{(i)}).$$

困难：高维图像分布复杂；既要能采样，又要有可计算的训练目标。

02 前向加噪

先设计一个容易实现的过程：从真实图片出发，一步一步加入噪声。

$$x_0 \xrightarrow{q} x_1 \xrightarrow{q} \cdots \xrightarrow{q} x_T.$$



- x_0 是原图，x_t 是加噪 t 步后的图像，x_T 是最后的状态。
- 加噪规则 q 由我们设定，不需要神经网络学习。
- 思路是先把图片逐渐变成噪声，再学习从噪声生成图片。

03 单步加噪公式

选定 $0 < \beta_t < 1$，定义 $\alpha_t = 1 - \beta_t$：

$$\boxed{q(x_t \mid x_{t-1}) = \mathcal{N}\left(x_t; \sqrt{\alpha_t} x_{t-1}, \beta_t I\right).}$$

等价的采样式为

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t, \qquad \epsilon_t \overset{\text{iid}}{\sim} \mathcal{N}(0, I).$$

- β_t 是方差，所以噪声系数为 $\sqrt{\beta_t}$。
- 信号与噪声的方差系数之和为 $\alpha_t + \beta_t = 1$。
- 若输入已是标准高斯，则输出仍是标准高斯；该分布是过程的固定点。

04 两步加噪推导

$$
\begin{aligned}
x_1 &= \sqrt{\alpha_1} x_0 + \sqrt{\beta_1}\epsilon_1, \\
x_2 &= \sqrt{\alpha_2} x_1 + \sqrt{\beta_2}\epsilon_2 \\
&= \sqrt{\alpha_1\alpha_2} x_0 + \sqrt{\alpha_2\beta_1}\epsilon_1 + \sqrt{\beta_2}\epsilon_2.
\end{aligned}
$$

两个噪声独立且高斯，线性组合仍是零均值高斯，其方差为

$$
(\alpha_2\beta_1 + \beta_2)I = [\alpha_2(1-\alpha_1) + (1-\alpha_2)]I = (1-\alpha_1\alpha_2)I.
$$

记 $\bar{\alpha}_2 = \alpha_1\alpha_2$，因此

$$
q(x_2 \mid x_0) = \mathcal{N}\big(x_2; \sqrt{\bar{\alpha}_2} x_0, (1-\bar{\alpha}_2)I\big).
$$

05 任意时刻的加噪公式

定义 $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$。假设第 $t-1$ 步的信号系数为 $\sqrt{\bar{\alpha}_{t-1}}$、噪声方差为 $1-\bar{\alpha}_{t-1}$。再执行一步，信号系数与噪声方差分别变为

$$\sqrt{\alpha_t}\sqrt{\bar{\alpha}_{t-1}} = \sqrt{\bar{\alpha}_t}, \qquad \alpha_t(1-\bar{\alpha}_{t-1}) + \beta_t = 1 - \bar{\alpha}_t.$$

结合第一步成立，归纳得到

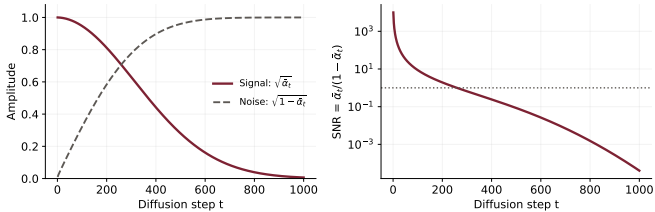
$$\boxed{q(x_t \mid x_0) = \mathcal{N}\left(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I\right).}$$

因此可直接采样

$$\boxed{x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon}, \qquad \epsilon \sim \mathcal{N}(0, I).$$

这里 ϵ 是该边缘采样式的**累计等效噪声**，不是单步噪声 ϵ_t。

06 加噪的终点



原文取 $T = 1000$、β_t 从 10^{-4} 线性增至 0.02，从而

$$\bar{\alpha}_T \approx 4.04 \times 10^{-5}, \quad q(x_T \mid x_0) \approx \mathcal{N}(0, I).$$

原图信号几乎消失，终点接近标准高斯噪声。因此可以尝试从高斯噪声出发，学习逐步生成图片。

07 反向生成模型

前向过程已将图片变成近似高斯噪声；现在学习相反方向的生成过程：

$$x_T \longrightarrow x_{T-1} \longrightarrow \cdots \longrightarrow x_0, \qquad p(x_T) = \mathcal{N}(0, I).$$

反向转移 $p_\theta(x_{t-1} \mid x_t)$ 需要学习；假设它只依赖当前状态，则

$$\boxed{p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t).}$$

但训练要用到的图像边缘概率是

$$p_\theta(x_0) = \int p_\theta(x_{0:T})\, dx_{1:T}.$$

训练问题：前向过程已经能构造带噪状态，但如何训练反向转移？图片似然的积分难以直接计算，因此接下来引入变分界。

08 将似然写成期望

前向轨迹分布与反向生成模型分别为

$$q(x_{1:T} \mid x_0) = \prod_{t=1}^{T} q(x_t \mid x_{t-1}), \qquad p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t).$$

在似然积分中乘除已知的前向分布 $q(x_{1:T} \mid x_0)$：

$$\begin{aligned} p_\theta(x_0) &= \int q(x_{1:T} \mid x_0) \frac{p_\theta(x_{0:T})}{q(x_{1:T} \mid x_0)} \, dx_{1:T} \\ &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[\frac{p_\theta(x_{0:T})}{q(x_{1:T} \mid x_0)} \right]. \end{aligned}$$

这是精确恒等式；还没有做近似，也没有得到最终训练损失。

09 用 Jensen 不等式求界

由于 log 是凹函数，$\log \mathbb{E}[Y] \geq \mathbb{E}[\log Y]$，因此

$$\boxed{\log p_\theta(x_0) \geq \mathbb{E}_q \left[\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} \mid x_0)} \right]}$$

沿用笔记第 6.1 节的记法，对给定的真实图片定义

$$\boxed{\mathcal{L}_{\text{VLB}} = \mathbb{E}_q \left[\log \frac{q(x_{1:T} \mid x_0)}{p_\theta(x_{0:T})} \right]}$$

$$\boxed{\log p_\theta(x_0) \geq -\mathcal{L}_{\text{VLB}}}$$

这里 $\mathbb{E}_q$ 对 $q(x_{1:T} \mid x_0)$ 取期望；。

10 展开 VLB

固定 x_0，以下 $\mathbb{E}_q = \mathbb{E}_{q(x_{1:T}|x_0)}$。

$$q(x_{1:T} \mid x_0) = \prod_{t=1}^{T} q(x_t \mid x_{t-1}) = q(x_1 \mid x_0) q(x_2 \mid x_1) \cdots q(x_T \mid x_{T-1}),$$
$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t) = p(x_T) p_\theta(x_{T-1} \mid x_T) \cdots p_\theta(x_0 \mid x_1).$$

$$\begin{aligned}
\mathcal{L}_{\text{VLB}} &= \mathbb{E}_q \left[\log \frac{q(x_{1:T}|x_0)}{p_\theta(x_{0:T})} \right] \\
&= \mathbb{E}_q \left[\log \frac{\prod_{t=1}^{T} q(x_t|x_{t-1})}{p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1}|x_t)} \right] \\
&= \mathbb{E}_q \left[\sum_{t=1}^{T} \log q(x_t \mid x_{t-1}) - \log p(x_T) - \sum_{t=1}^{T} \log p_\theta(x_{t-1} \mid x_t) \right].
\end{aligned}$$

$$\begin{aligned}
q(x_{t-1} \mid x_t, x_0) &= \frac{q(x_t|x_{t-1}, x_0) q(x_{t-1}|x_0)}{q(x_t|x_0)} \\
&= \frac{q(x_t|x_{t-1}) q(x_{t-1}|x_0)}{q(x_t|x_0)}, \qquad t \geq 2.
\end{aligned}$$

$$\begin{aligned}
&\log q(x_{t-1} \mid x_t, x_0) = \log q(x_t \mid x_{t-1}) + \log q(x_{t-1} \mid x_0) - \log q(x_t \mid x_0), \\
\Longrightarrow \quad &\log q(x_t \mid x_{t-1}) = \log q(x_{t-1} \mid x_t, x_0) - \log q(x_{t-1} \mid x_0) + \log q(x_t \mid x_0).
\end{aligned}$$

11 消去中间项

$$
\begin{aligned}
\sum_{t=1}^{T} \log q(x_t \mid x_{t-1}) &= \log q(x_1 \mid x_0) + \sum_{t=2}^{T} \log q(x_t \mid x_{t-1}) \\
&= \log q(x_1 \mid x_0) + \sum_{t=2}^{T} \log q(x_{t-1} \mid x_t, x_0) \\
&\quad - \sum_{t=2}^{T} \log q(x_{t-1} \mid x_0) + \sum_{t=2}^{T} \log q(x_t \mid x_0).
\end{aligned}
$$

$$
\begin{aligned}
&- \sum_{t=2}^{T} \log q(x_{t-1} \mid x_0) + \sum_{t=2}^{T} \log q(x_t \mid x_0) \\
&= \left[- \log q(x_1 \mid x_0) - \cdots - \log q(x_{T-1} \mid x_0) \right] + \left[\log q(x_2 \mid x_0) + \cdots + \log q(x_T \mid x_0) \right] \\
&= - \log q(x_1 \mid x_0) + \log q(x_T \mid x_0).
\end{aligned}
$$

$$
\boxed{\sum_{t=1}^{T} \log q(x_t \mid x_{t-1}) = \log q(x_T \mid x_0) + \sum_{t=2}^{T} \log q(x_{t-1} \mid x_t, x_0).}
$$

$$
\sum_{t=1}^{T} \log p_\theta(x_{t-1} \mid x_t) = \sum_{t=2}^{T} \log p_\theta(x_{t-1} \mid x_t) + \log p_\theta(x_0 \mid x_1).
$$

$$
\begin{aligned}
\mathcal{L}_{\mathrm{VLB}} &= \mathbb{E}_q \Big[\log q(x_T \mid x_0) - \log p(x_T) + \sum_{t=2}^{T} \log q(x_{t-1} \mid x_t, x_0) \\
&\qquad - \sum_{t=2}^{T} \log p_\theta(x_{t-1} \mid x_t) - \log p_\theta(x_0 \mid x_1) \Big] \\
&= \mathbb{E}_q \left[\log \tfrac{q(x_T \mid x_0)}{p(x_T)} + \sum_{t=2}^{T} \log \tfrac{q(x_{t-1} \mid x_t, x_0)}{p_\theta(x_{t-1} \mid x_t)} - \log p_\theta(x_0 \mid x_1) \right].
\end{aligned}
$$

12 将期望转为 KL

$$D_{\mathrm{KL}}(q\|p) = \mathbb{E}_q\left[\log \tfrac{q}{p}\right] = \int q(x)\log\tfrac{q(x)}{p(x)}\,dx.$$

$$\begin{aligned}\mathbb{E}_q\left[\log \tfrac{q(x_T|x_0)}{p(x_T)}\right] &= \int q(x_{1:T}\mid x_0)\log\tfrac{q(x_T|x_0)}{p(x_T)}\,dx_{1:T}\\ &= \int q(x_T\mid x_0)\log\tfrac{q(x_T|x_0)}{p(x_T)}\,dx_T\\ &= D_{\mathrm{KL}}\big(q(x_T\mid x_0)\|p(x_T)\big).\end{aligned}$$

$$q(x_{t-1}, x_t\mid x_0) = q(x_t\mid x_0)q(x_{t-1}\mid x_t, x_0), \qquad t\geq 2.$$

$$\begin{aligned}&\mathbb{E}_q\left[\log\tfrac{q(x_{t-1}|x_t,x_0)}{p_\theta(x_{t-1}|x_t)}\right]\\ &= \iint q(x_{t-1}, x_t\mid x_0)\log\tfrac{q(x_{t-1}|x_t,x_0)}{p_\theta(x_{t-1}|x_t)}\,dx_{t-1}\,dx_t\\ &= \iint q(x_t\mid x_0)q(x_{t-1}\mid x_t,x_0)\log\tfrac{q(x_{t-1}|x_t,x_0)}{p_\theta(x_{t-1}|x_t)}\,dx_{t-1}\,dx_t\\ &= \int q(x_t\mid x_0)\left[\int q(x_{t-1}\mid x_t,x_0)\log\tfrac{q(x_{t-1}|x_t,x_0)}{p_\theta(x_{t-1}|x_t)}\,dx_{t-1}\right]dx_t\\ &= \mathbb{E}_{q(x_t|x_0)}\left[D_{\mathrm{KL}}\big(q(x_{t-1}\mid x_t,x_0)\|p_\theta(x_{t-1}\mid x_t)\big)\right].\end{aligned}$$

13 合并 VLB 损失

$$\sum_{t=2}^{T} \mathbb{E}_q \left[\log \frac{q(x_{t-1}|x_t, x_0)}{p_\theta(x_{t-1}|x_t)} \right] = \sum_{t=2}^{T} \mathbb{E}_{q(x_t|x_0)} \left[D_{\mathrm{KL}}\big(q(x_{t-1} \mid x_t, x_0) \| p_\theta(x_{t-1} \mid x_t)\big) \right],$$

$$-\mathbb{E}_q[\log p_\theta(x_0 \mid x_1)] = -\mathbb{E}_{q(x_1|x_0)}[\log p_\theta(x_0 \mid x_1)].$$

$$\begin{aligned} \mathcal{L}_{\mathrm{VLB}}(x_0) = {} & D_{\mathrm{KL}}\big(q(x_T \mid x_0) \| p(x_T)\big) \\ & + \sum_{t=2}^{T} \mathbb{E}_{q(x_t|x_0)} \left[D_{\mathrm{KL}}\big(q(x_{t-1} \mid x_t, x_0) \| p_\theta(x_{t-1} \mid x_t)\big) \right] \\ & + \mathbb{E}_{q(x_1|x_0)}[-\log p_\theta(x_0 \mid x_1)]. \end{aligned}$$

$$= \mathbb{E}_q \Big[\underbrace{D_{\mathrm{KL}}\big(q(x_T \mid x_0) \| p(x_T)\big)}_{\text{终点匹配}} + \sum_{t=2}^{T} \underbrace{D_{\mathrm{KL}}\big(q(x_{t-1} \mid x_t, x_0) \| p_\theta(x_{t-1} \mid x_t)\big)}_{\text{反向转移匹配}} \underbrace{- \log p_\theta(x_0 \mid x_1)}_{\text{最终解码}} \Big].$$

$$\min_\theta \ \mathbb{E}_{x_0 \sim p_{\mathrm{data}}} \left[\mathcal{L}_{\mathrm{VLB}}(x_0) \right].$$

14 展开后验分布

对于 $t \geq 2$，由贝叶斯公式：

$$q(x_{t-1} \mid x_t, x_0) = \frac{q(x_t \mid x_{t-1}, x_0)\, q(x_{t-1} \mid x_0)}{q(x_t \mid x_0)}.$$

固定 x_t, x_0，分母与 x_{t-1} 无关，只负责归一化。前向过程满足 $q(x_t \mid x_{t-1}, x_0) = q(x_t \mid x_{t-1})$。

为何仍是高斯？ 分子两项的指数都是关于 x_{t-1} 的二次式。相乘后，指数相加，仍可配方成高斯形式。

令 $y = x_{t-1}$，$a = \bar{\alpha}_{t-1}$，$\alpha = \alpha_t$，$\beta = \beta_t$。

$$q(y \mid x_t, x_0) \propto \exp\left[-\frac{1}{2}\left(\frac{\|x_t - \sqrt{\alpha} y\|^2}{\beta} + \frac{\|y - \sqrt{a} x_0\|^2}{1-a}\right)\right].$$

分别展开平方，保留与 y 有关的二次项和一次项：

$$-\frac{1}{2}\left[\left(\frac{\alpha}{\beta} + \frac{1}{1-a}\right)\|y\|^2 - 2y^\top\left(\frac{\sqrt{\alpha}}{\beta} x_t + \frac{\sqrt{a}}{1-a} x_0\right)\right].$$

二次项的系数是精度；一次项将用于求后验均值。

15 求后验均值与方差

$$\tilde{\beta}_t = \left(\frac{\alpha}{\beta} + \frac{1}{1-a}\right)^{-1} = \frac{\beta(1-a)}{\alpha(1-a)+\beta} = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t.$$

这里使用 $\alpha + \beta = 1$ 和 $\alpha a = \bar{\alpha}_t$。方差乘以一次项系数得到

$$\tilde{\mu}_t = \tilde{\beta}_t \left(\frac{\sqrt{\alpha_t}}{\beta_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}} x_0\right).$$

$$\boxed{\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t.}$$

故 $q(x_{t-1} \mid x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I)$ $(t \geq 2)$。

16 反向模型的均值与方差

定义模型

$$p_\theta(x_{t-1} \mid x_t) = \mathcal{N}\left(x_{t-1}; \mu_\theta(x_t, t), \sigma_t^2 I\right).$$

- 给定 x_0 的后验是精确高斯；未给定 x_0 的真实反向分布通常是混合分布。
- 用小步长的高斯转移近似复杂反向过程，是模型的选择。
- 本汇报采用原文固定方差设置，如 $\sigma_t^2 = \beta_t$ 或 $\tilde{\beta}_t$。

$$\underbrace{\mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t I)}_{\text{训练中可计算的目标}} \quad \longleftrightarrow \quad \underbrace{\mathcal{N}(\mu_\theta, \sigma_t^2 I)}_{\text{需要学习的模型}}.$$

17 从 KL 到均值误差

$$D_{\mathrm{KL}}(q\|p) = \frac{1}{2}\Bigg[\operatorname{tr}(\Sigma_p^{-1}\Sigma_q) + (\mu_p-\mu_q)^\top \Sigma_p^{-1}(\mu_p-\mu_q) - d + \log\frac{\det\Sigma_p}{\det\Sigma_q}\Bigg].$$

代入 $\Sigma_q = \tilde{\beta}_t I$、$\Sigma_p = \sigma_t^2 I$；两个方差固定，只有均值误差依赖 θ：

$$\boxed{L_{t-1} = \frac{1}{2\sigma_t^2}\mathbb{E}_q\left[\|\tilde{\mu}_t - \mu_\theta\|^2\right] + \text{常数}}$$

已有可训练方案：让网络直接回归后验均值 $\tilde{\mu}_t$。但前向过程也给出了真实噪声标签 ϵ。

18 用噪声表示原图

$$\boxed{x_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}}}$$

把它代入后验均值，先完整保留代入后的两项：

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}\frac{x_t - \sqrt{1-\bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}} + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t.$$

利用 $\bar{\alpha}_t = \bar{\alpha}_{t-1}\alpha_t$，有 $\sqrt{\bar{\alpha}_{t-1}}/\sqrt{\bar{\alpha}_t} = 1/\sqrt{\alpha_t}$。

19 用噪声预测计算均值

$$\frac{\beta_t + \alpha_t(1-\bar{\alpha}_{t-1})}{\sqrt{\alpha_t}(1-\bar{\alpha}_t)} = \frac{1-\bar{\alpha}_t}{\sqrt{\alpha_t}(1-\bar{\alpha}_t)} = \frac{1}{\sqrt{\alpha_t}}.$$

于是精确后验均值为

$$\tilde{\mu}_t(x_t, x_0) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon\right).$$

生成时真实 ϵ 未知，定义噪声网络并令

$$\boxed{\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right).}$$

20 带权噪声损失

$$\tilde{\mu}_t - \mu_\theta = \frac{\beta_t}{\sqrt{\alpha_t}\sqrt{1-\bar{\alpha}_t}}\big(\epsilon_\theta(x_t,t) - \epsilon\big).$$

$$\|\tilde{\mu}_t - \mu_\theta\|^2 = \frac{\beta_t^2}{\alpha_t(1-\bar{\alpha}_t)}\|\epsilon - \epsilon_\theta(x_t,t)\|^2.$$

代回高斯 KL 的均值误差项:

$$\boxed{L_{t-1} = \mathbb{E}_{x_0,\epsilon}\left[\frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\bar{\alpha}_t)}\|\epsilon - \epsilon_\theta(x_t,t)\|^2\right] + \text{常数}.}$$

其中 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$; 此推导针对 $t \geq 2$。

21 简化噪声损失

每次从 1 到 T 等概率抽取一步 t，计算真实噪声与预测噪声的平方误差：

$$\boxed{\mathcal{L}_{\text{simple}}(\theta) = \mathbb{E}_{t,x_0,\epsilon}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|^2\right]}$$

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$$

- **怎么算：**先用 x_0 和噪声 ϵ 构造 x_t，再让网络预测 ϵ。
- **简化了什么：**各时间步都用同一个误差公式，不再乘不同的 w_t。
- **为什么这样做：**论文实验发现，这样训练得到的图片质量更好。

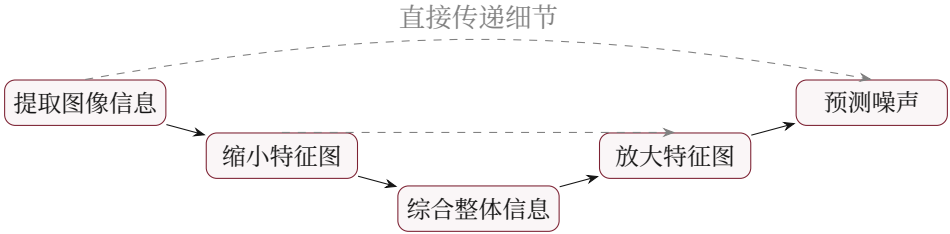
注意：这是修改后的训练损失，与原来的 $\mathcal{L}_{\text{VLB}}$ 不完全相同。

22 训练流程

1. 取训练图像 $x_0 \sim q(x_0)$，随机取 $t \sim \text{Uniform}\{1, \ldots, T\}$。
2. 采样 $\epsilon \sim \mathcal{N}(0, I)$，构造
$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon.$$
3. 调用一次网络 $\hat{\epsilon} = \epsilon_\theta(x_t, t)$。
4. 计算 $\|\epsilon - \hat{\epsilon}\|^2$，反向传播并更新 θ。



23 U-Net 网络



- **输入：**带噪图片 x_t 和时间步 t。时间步告诉网络现在进行到哪一步。
- **处理：**先缩小特征图，看整体；再放大，并接回前面保留的细节。
- **输出：**为每个像素通道预测噪声，输出与输入图片同样大小。
- **自注意力：**在 16×16 的中间特征图上，让各个位置互相参考。
- **GroupNorm：**分组调整中间数值，让训练更稳定。

24 单步去噪

对当前状态 x_t，先计算

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right).$$

再从 $p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(\mu_\theta, \sigma_t^2 I)$ 采样：

$$\boxed{x_{t-1} = \mu_\theta(x_t, t) + \sigma_t z, \qquad z \sim \mathcal{N}(0, I).}$$

- ϵ_θ 用于确定均值；z 是本次转移新采样的随机量。
- σ_t 是标准差；若选择方差 β_t，则 $\sigma_t = \sqrt{\beta_t}$。
- 最后 $t = 1$ 时按原文算法令 $z = 0$，返回最终去噪均值。

25 完整生成流程

1. 初始化 $x_T \sim \mathcal{N}(0, I)$。
2. 对 $t = T, T-1, \ldots, 1$：

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z.$$

   其中 $t > 1$ 时 $z \sim \mathcal{N}(0, I)$，否则 $z = 0$。
3. 返回 x_0。

训练：随机抽一个时间步，估计总体训练损失。

采样：必须先获得 x_{t-1}，才能调用下一次 $\epsilon_\theta(x_{t-1}, t-1)$。

26 不同训练方案对比

Table 2: Unconditional CIFAR10 reverse process parameterization and training objective ablation. Blank entries were unstable to train and generated poor samples with out-of-range scores.

Objective	IS	FID
$\tilde{\mu}$ prediction (baseline)		
L, learned diagonal Σ	7.28 ± 0.10	23.69
L, fixed isotropic Σ	8.06 ± 0.09	13.22
$\|\tilde{\mu} - \tilde{\mu}_\theta\|^2$	–	–
ϵ prediction (ours)		
L, learned diagonal Σ	–	–
L, fixed isotropic Σ	7.67 ± 0.13	13.51
$\|\tilde{\epsilon} - \epsilon_\theta\|^2$ (L_{simple})	$\mathbf{9.46 \pm 0.11}$	**3.17**

- 表中同时比较均值预测、噪声预测，以及不同方差和损失设置；这里重点看固定方差的三行。
- Mean + VLB 与 Noise + VLB 的 FID 接近，改参数化本身并未直接带来大幅提升。
- Noise + simple 的 FID 降到 3.17，支持二者结合的有效性。

IS（Inception 分数）：衡量生成图片的类别是否清楚、种类是否丰富，越高越好。

FID：衡量生成图片与真实图片的特征分布差异，越低越好。

27 生成质量与似然对比

Table 1: CIFAR10 results. NLL measured in bits/dim.

Model	IS	FID	NLL Test (Train)
Conditional			
EBM [11]	8.30	37.9	
JEM [17]	8.76	38.4	
BigGAN [3]	9.22	14.73	
StyleGAN2 + ADA (v1) [29]	**10.06**	**2.67**	
Unconditional			
Diffusion (original) [53]			≤ 5.40
Gated PixelCNN [59]	4.60	65.93	3.03 (2.90)
Sparse Transformer [7]			**2.80**
PixelIQN [43]	5.29	49.46	
EBM [11]	6.78	38.2	
NCSNv2 [56]		31.75	
NCSN [55]	8.87 ± 0.12	25.32	
SNGAN [39]	8.22 ± 0.05	21.7	
SNGAN-DDLS [4]	9.09 ± 0.10	15.42	
StyleGAN2 + ADA (v1) [29]	$\mathbf{9.74} \pm 0.05$	3.26	
Ours (L, fixed isotropic $\mathbf{\Sigma}$)	7.67 ± 0.13	13.51	≤ 3.70 (3.69)
Ours (L_{simple})	9.46 ± 0.11	**3.17**	≤ 3.75 (3.72)

- **NLL（负对数似然）：**衡量模型对真实数据的概率预测，越低越好。表中报告的是其上界。
- 重点看底部两行 Ours：比较 VLB 与简化损失。
- 简化损失的 FID 更低，但测试 NLL 上界从 3.70 变为 3.75。

结论：简化损失改善了生成图片的质量，但不保证更好的似然指标。