浙江大學
ZHEJIANG UNIVERSITY

JoSE · ICML 2026 spotlight

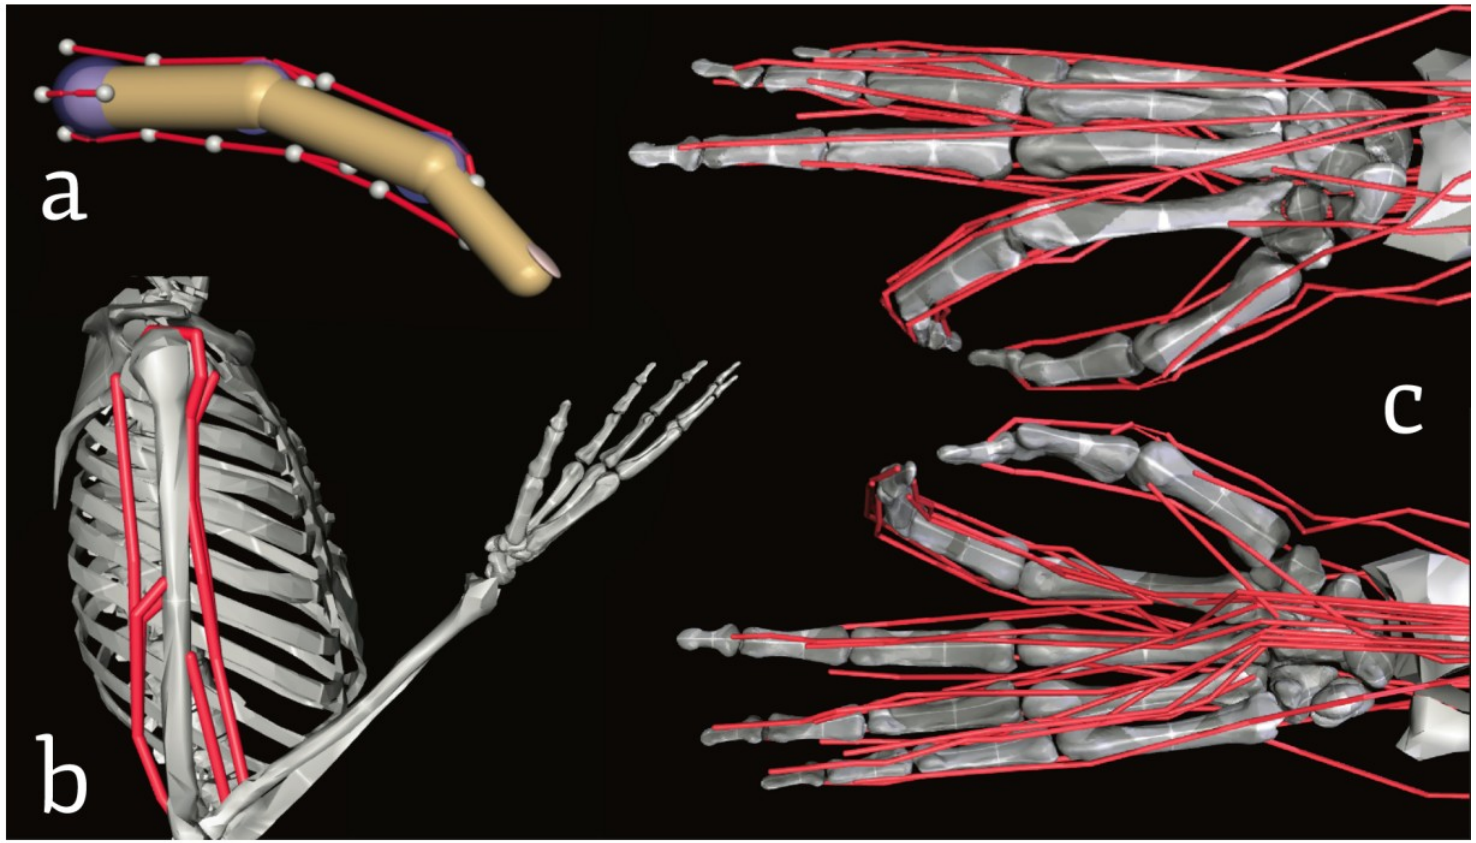
Joint-Space Empowerment for Dexterous Coordination in Tendon-Driven Hands

关节空间赋能：肌腱驱动手的灵巧协调

James Heald · Vittorio Caggiano · Vikash Kumar · Maneesh Sahani

ICML 2026

MyoSuite： 可交互的肌肉骨骼模型



肌肉骨骼模型

包括手指、上肢与手部模型，覆盖不同控制规模

控制接口

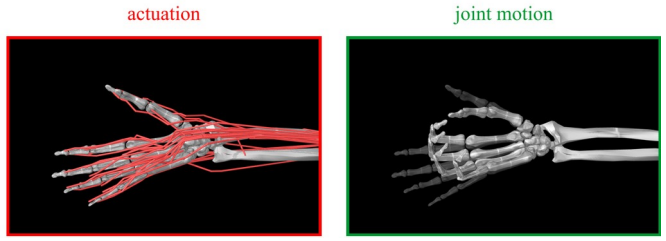
策略输出肌肉控制指令，仿真环境返回观测与奖励

任务设置

同一模型可设置不同目标、负载和接触条件

Caggiano et al., 2022 • MyoSuite models

MyoHand： 肌肉指令、激活、张力与关节运动



变量	大小	物理含义
a	39 维	策略送入执行器（肌肉 / 肌腱）的控制输入
m	39 维	随时间逐渐变化的肌肉激活状态
F	39 维	各肌肉—肌腱单元产生的拉力
q / $\dot{q}$	23 维	手与腕关节角度 / 角速度

23 自由度 · 29 块骨

$$\dot{\mathbf{m}} = \varphi(\mathbf{m}, \mathbf{a}), \qquad \mathbf{F} = \mathbf{F}(\mathbf{m}, \ell(\mathbf{q}), \dot{\ell}(\mathbf{q}, \dot{\mathbf{q}}))$$

φ： 激活动力学　ℓ: 肌肉—肌腱路径长度　$\dot{\ell}$： 路径长度变化率

MyoHand：一个控制周期中的仿真更新

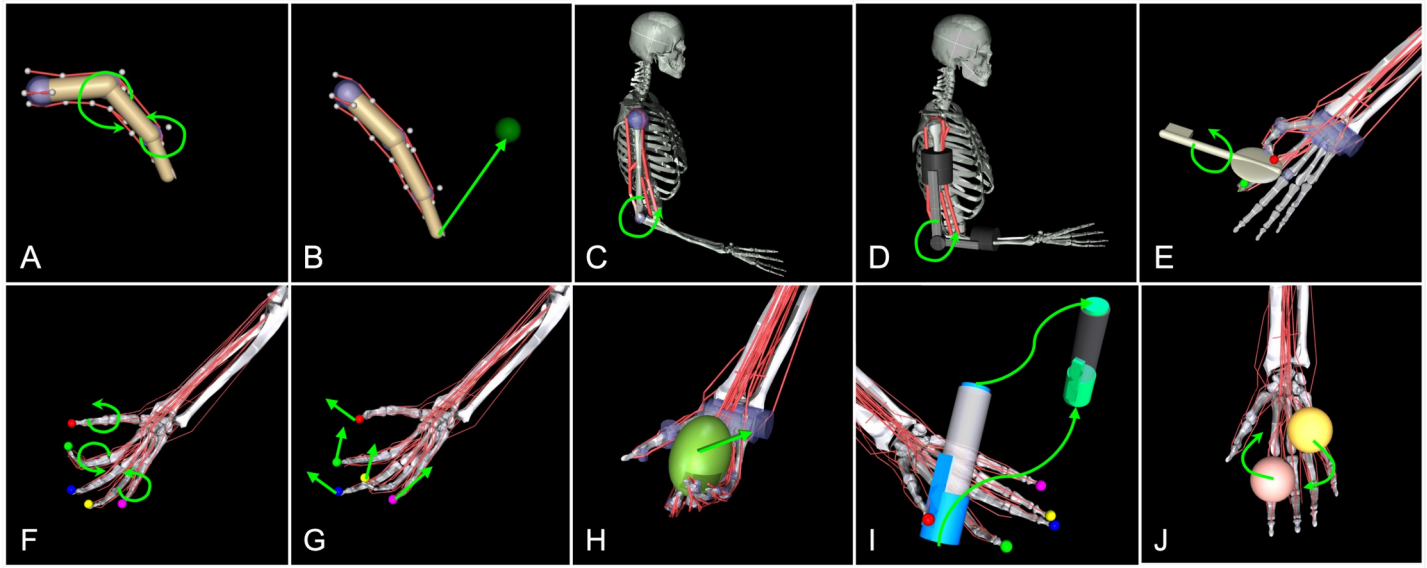
$$\mathbf{M}(\mathbf{q})\ddot{\mathbf{q}} + \mathbf{C}(\mathbf{q}, \dot{\mathbf{q}})\dot{\mathbf{q}} + \mathbf{g}(\mathbf{q}) = \mathbf{D}(\mathbf{q})\mathbf{F} + \boldsymbol{\tau}_{\text{ext}}$$

M： 质量 / 惯性矩阵　Cq̇：速度相关项　g： 重力项

D： 肌腱力臂映射　τext： 接触等外力矩　q̈： 关节加速度

计算环节	当前输入与输出
1. 激活与肌腱几何	a 更新 m； q 、 q̇更新路径长度、变化速度和力臂
2. 肌肉力与关节力矩	肌肉力—长、力—速特性及被动弹性共同决定 F； D 将拉力映射为关节力矩
3. 接触与运动求解	肌肉拉力、重力与接触摩擦共同参与动力学求解
4. 积分与返回观测	积分更新角度、速度和物体状态，再返回观测及任务奖励

接触操作：状态、计算与控制难点



状态

手部与物体的位姿、速度和肌肉激活影响当前接触状态

仿真计算

检测接触并求解约束
计算法向作用与摩擦力

控制难点

接触建立、滑动或分离会改变同一输入的运动效果

JoSE 作者的研究方向

James Heald： 概率学习与控制

James Heald

I develop algorithms for learning dexterous manipulation, combining reinforcement learning and probabilistic machine learning. Most recently, this has led to an ICML 2026 Spotlight paper (top 2.2% of submissions), a NeurIPS 2026 paper, and a NeurIPS 2024 competition-winning method.

I am a Research Fellow at the Gatsby Unit, UCL working with Maneesh Sahani. I previously worked as a postdoctoral researcher at the Zuckerman Institute, Columbia University with Daniel Wolpert, where I published a first-author paper in *Nature*. I received a PhD in Engineering from the University of Cambridge, where I trained in the Computational and Biological Learning Lab. Prior to my PhD, I worked as a medical doctor in the NHS, and before that, I received an MSc in Cognitive and Computational Neuroscience from The University of Sheffield and an MBChB in Medicine from The University of Manchester.

Email / Resume / Google Scholar / GitHub / LinkedIn / Twitter



Vittorio Caggiano： 肌肉骨骼运动控制



Vittorio Caggiano

Director, Meta FAIR · Embodied AI

About me

Director at **Meta FAIR** working on **embodied AI**, with a rare full-stack profile across **frontier AI research, systems engineering, and organizational leadership**. Previously founded MyoLab, and at Meta AI led the development and launch of foundational open-source infrastructure – FairScale and xFormers, (as TPM) and MyoSuite (as researcher and technical lead) – now totaling 15k+ GitHub stars and 125M+ downloads. Previously led 30+ person cross-functional teams at IBM Research.

I am also an Adjunct Lecturer at **King's College London**.

Heald / Sahani

强化学习、概率建模和灵巧操作

Caggiano / Kumar

肌肉骨骼仿真、强化学习与灵巧操作

JoSE （2026）：冗余的收益与协调代价

肌腱驱动的结构

电机或肌肉经肌腱传递拉力；腱索只能拉，双向驱动通常需要拮抗配置

冗余的价值

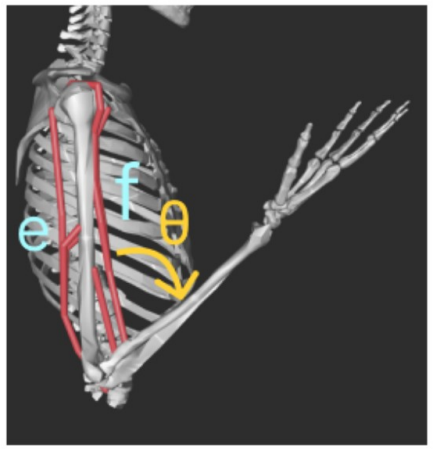
拮抗肌共同激活可以调节刚度；冗余执行器也提供额外的控制选择

学习的困难

不同肌肉输入可能产生近似相同的关节运动，直接探索会增加协调难度

肌肉输入不同，关节运动未必不同

A



$$\delta\dot{q}_{t+1} \approx \kappa(\delta a_{1,t} - \delta a_{2,t}), \qquad \mathbf{G}(\mathbf{s}_t) \approx \kappa \begin{bmatrix} 1 & -1 \end{bmatrix}$$

δa：肌肉输入变化　δq̇：下一步角速度变化　κ：响应系数

G(s)：当前状态下输入对下一步关节角速度的响应

局部对称近似：差动输入改变净力矩，共同输入的作用近似抵消。

短时关节运动　　下一时刻关节运动未必可用于区分肌肉状态

拮抗肌示意： Lattice · Fig. 2A

浙江大学 ZHEJIANG UNIVERSITY

从肌肉输入到关节运动：三段动力学

肌肉控制指令依次影响激活状态、肌肉—肌腱张力和关节动力学，最终改变关节运动。

① 肌肉激活动力学

$$\dot{m} = \alpha_1(s) + \beta_1(s)a$$

刺激指令 a 调节激活状态 m；激活有时间常数，无法瞬时变化。

② 肌肉—肌腱力生成

$$f_t = \alpha_2(q, \dot{q}) + \beta_2(q, \dot{q})m$$

肌肉激活、长度与收缩速度共同影响肌肉—肌腱拉力 f_t。

③ 关节刚体动力学

$$M(q)\ddot{q} + C(q, \dot{q})\dot{q} + g(q) = P^T(q)f_t$$

肌腱张力经力臂转换为关节力矩，再结合惯性、重力等求解运动。

$$p_\psi(\mathbf{y}_{t+1} \mid \mathbf{s}_t, \mathbf{a}_t) = \mathcal{N}(\mathbf{f}(\mathbf{s}_t) + \mathbf{G}(\mathbf{s}_t)\mathbf{a}_t,\ \mathbf{Q}(\mathbf{s}_t))$$

动力学矩阵 G(s)：肌肉指令怎样影响关节速度

$$p_\psi(\mathbf{y}_{t+1} \mid \mathbf{s}_t, \mathbf{a}_t) = \mathcal{N}(\mathbf{f}(\mathbf{s}_t) + \mathbf{G}(\mathbf{s}_t)\mathbf{a}_t,\ \mathbf{Q}(\mathbf{s}_t))$$

y： 下一步关节角速度　f： 基线预测　G： 输入响应矩阵　Q： 噪声协方差

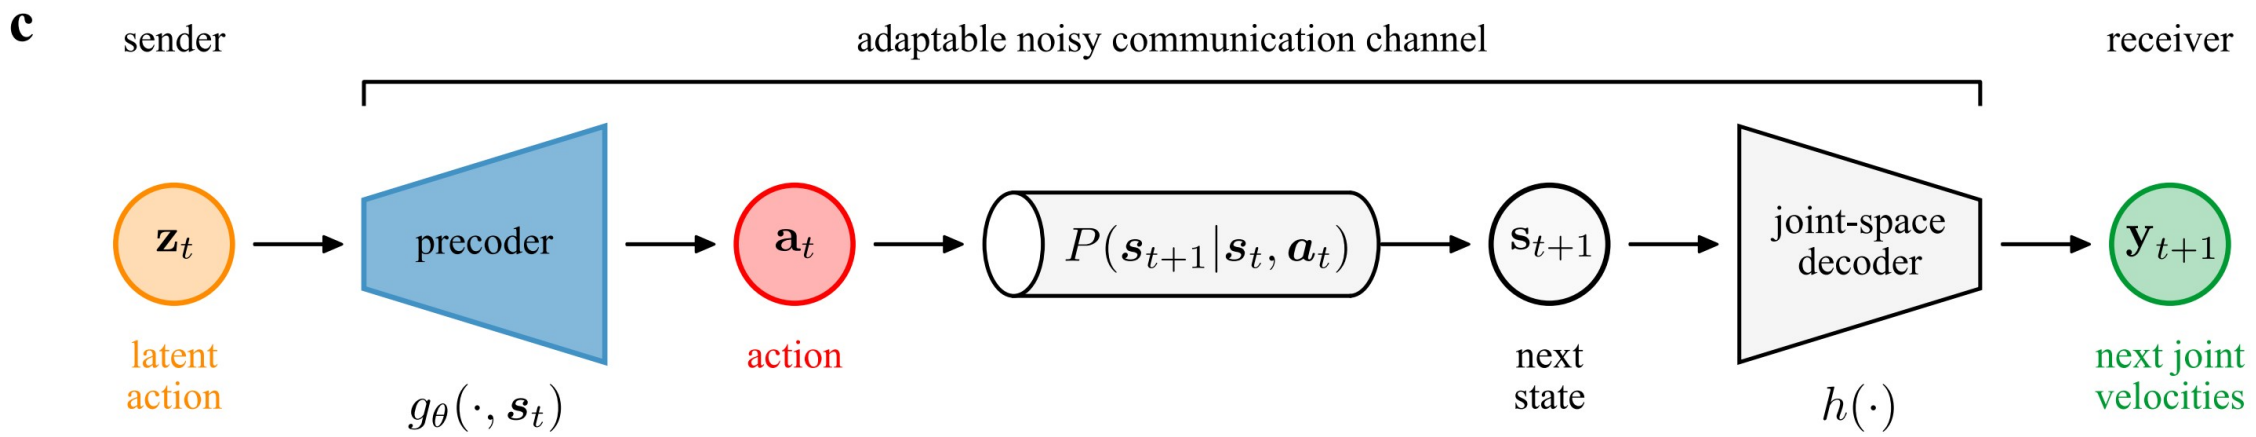
基础项 f　　给定当前状态且 a = 0 时的关节速度基线预测

响应矩阵 G　　每一列描述对应肌肉输入对下一步关节速度的影响

条件噪声 Q　　给定状态和动作后，下一步关节速度的剩余不确定性

从潜在动作到关节角速度：通信通道视角

潜动作 z_t　　**预编码器 $g\theta$**　　**环境动力学 P**　　**关节速度提取 h**



$$\mathbf{a}_t = g_{\boldsymbol{\theta}}(\mathbf{z}_t, \mathbf{s}_t), \qquad \mathbf{s}_{t+1} \sim P(\cdot \mid \mathbf{s}_t, \mathbf{a}_t), \qquad \mathbf{y}_{t+1} = h(\mathbf{s}_{t+1})$$

状态 s_t

手部与操作物体的当前状态

潜动作 z_t

策略选择的低维动作坐标

输入 a_t

gθ：将潜在动作映射为肌肉控制指令

输出 y_{t+1}

h：从下一状态提取关节角速度

JoSE 的核心思想：动作能产生多样且可靠的关节运动

1 信道模型

$$a = \theta z, \qquad y = f + G\theta z + \varepsilon$$

固定状态 s：潜在动作 z 经 θ 转为肌肉输入，再由 G 影响下一步关节速度。

2 互信息

$$I(z;y) = H(y) - H(y \mid z) = \frac{1}{2}\log\det\left(I + \widetilde{G}\theta\Sigma\theta^{T}\widetilde{G}^{T}\right)$$

$z \sim N(0,\Sigma)$， $\varepsilon \sim N(0,Q)$； $\tilde{G} = Q^{-1/2}G$ 对输出噪声进行白化。

3 输入功率约束

$$\max I(z;y) \qquad \text{s.t.} \quad \operatorname{tr}(\theta\Sigma\theta^{T}) = P_{\text{tx}}$$

在平均肌肉输入功率受限时，联合选择 θ 与潜变量分布。

4 最优子空间

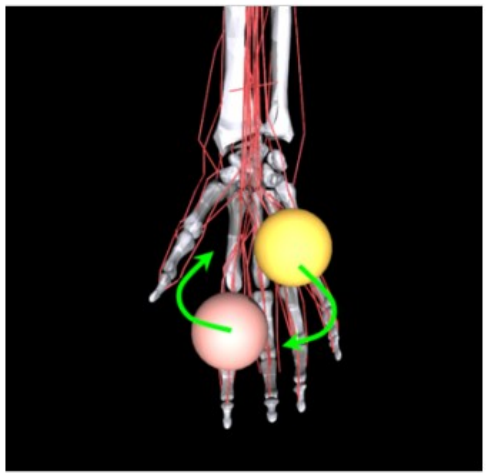
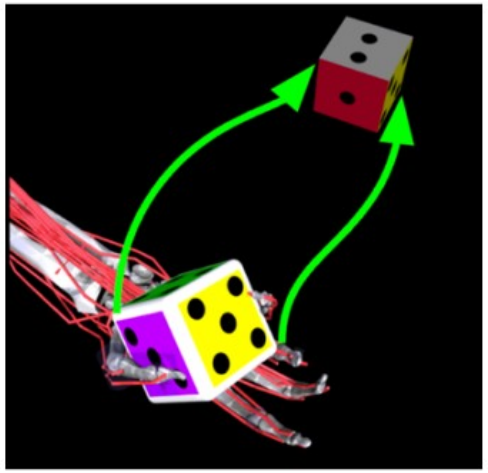
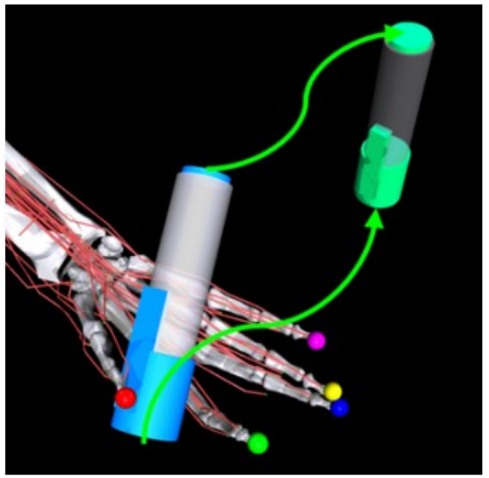
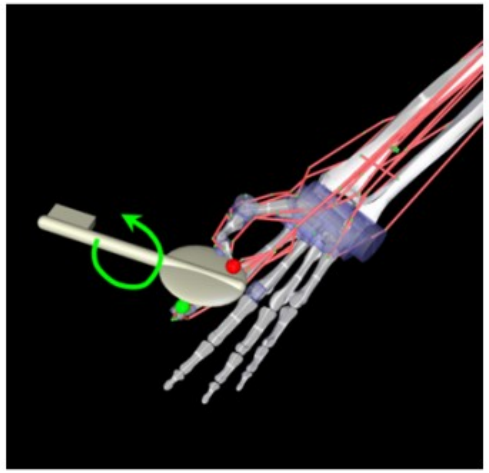
$$\widetilde{G} = Q^{-1/2}G = U_r S_r V_r^{T} \quad \Longrightarrow \quad \theta^{*} = V_r$$

零空间不增加互信息；取非零奇异值对应的右奇异向量张成最优子空间。

实现中： $G \approx LR$； 当 L 满列秩时， R 的归一化行向量可张成同一动作子空间。

四项手内操作任务与评价指标

保定球　　骰子重定向　　转笔　　转钥匙

$$\text{fraction solved} = \frac{\sum_{t=1}^{T} \mathbb{1}\{\mathbf{s}_t \text{ solved}\}}{T_{\max}}$$

T： 实际回合步数　Tmax： 回合最大步数　1{solved}： 当前步满足成功判据则为 1

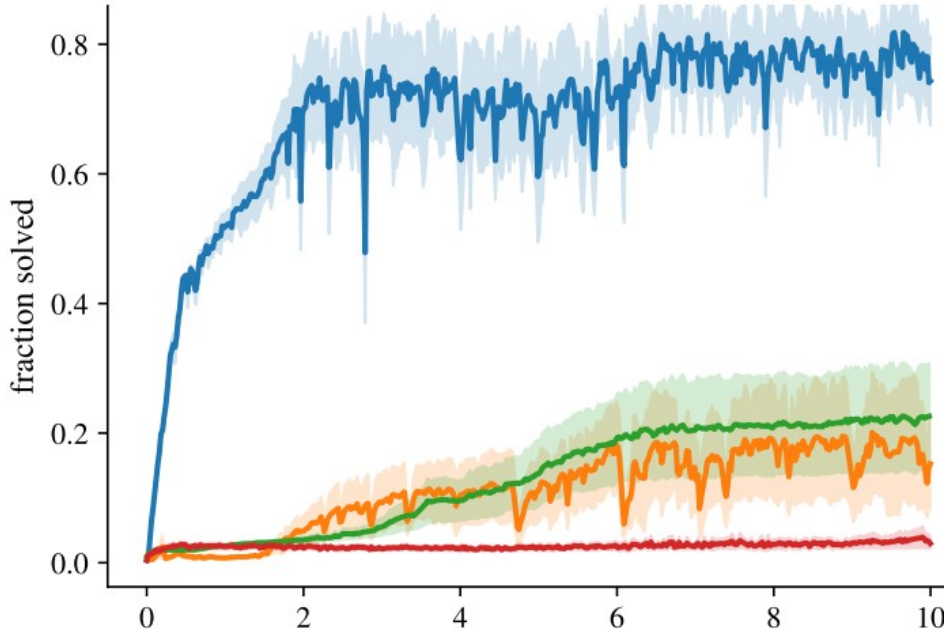
对照： SAC 、 Lattice-SAC 、 Lattice-rPPO 。

达标步数占比 = 达标步数 / 回合最大步数。

保定球与骰子重定向的学习结果

JoSEPi　　Lattice-SAC　　Lattice-rPPO　　SAC

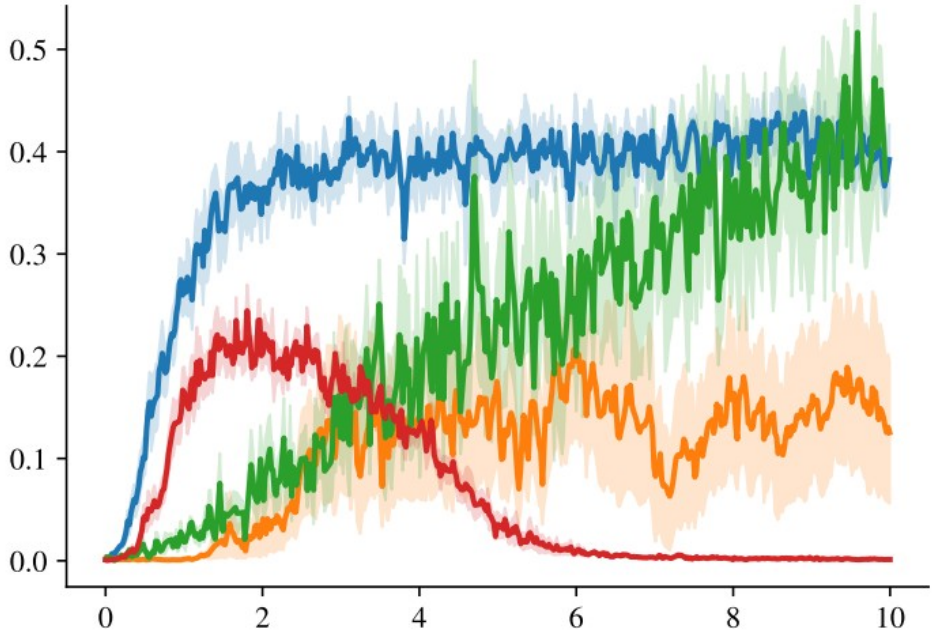
保定球（双球旋转）



横轴：环境交互步数（百万）　纵轴：达标步数占比

结论：更快形成多指协调，样本效率更高。

骰子重定向

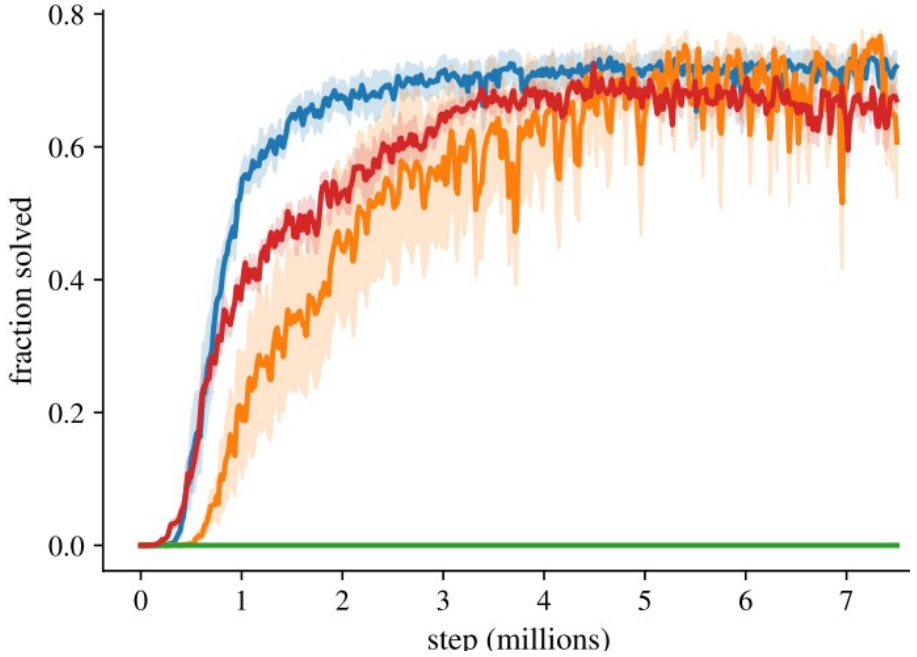


结论：更早达到较高的达标步数占比，最终表现也更好。

转钥匙与转笔的学习结果

JoSEPi　　Lattice-SAC　　Lattice-rPPO　　SAC

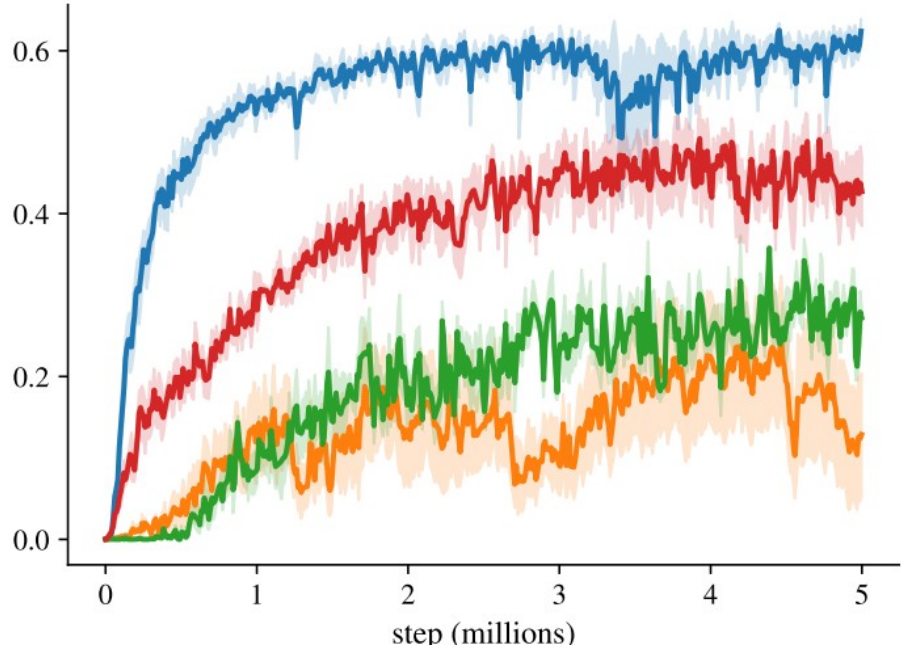
转钥匙



横轴：环境交互步数（百万）　纵轴：达标步数占比

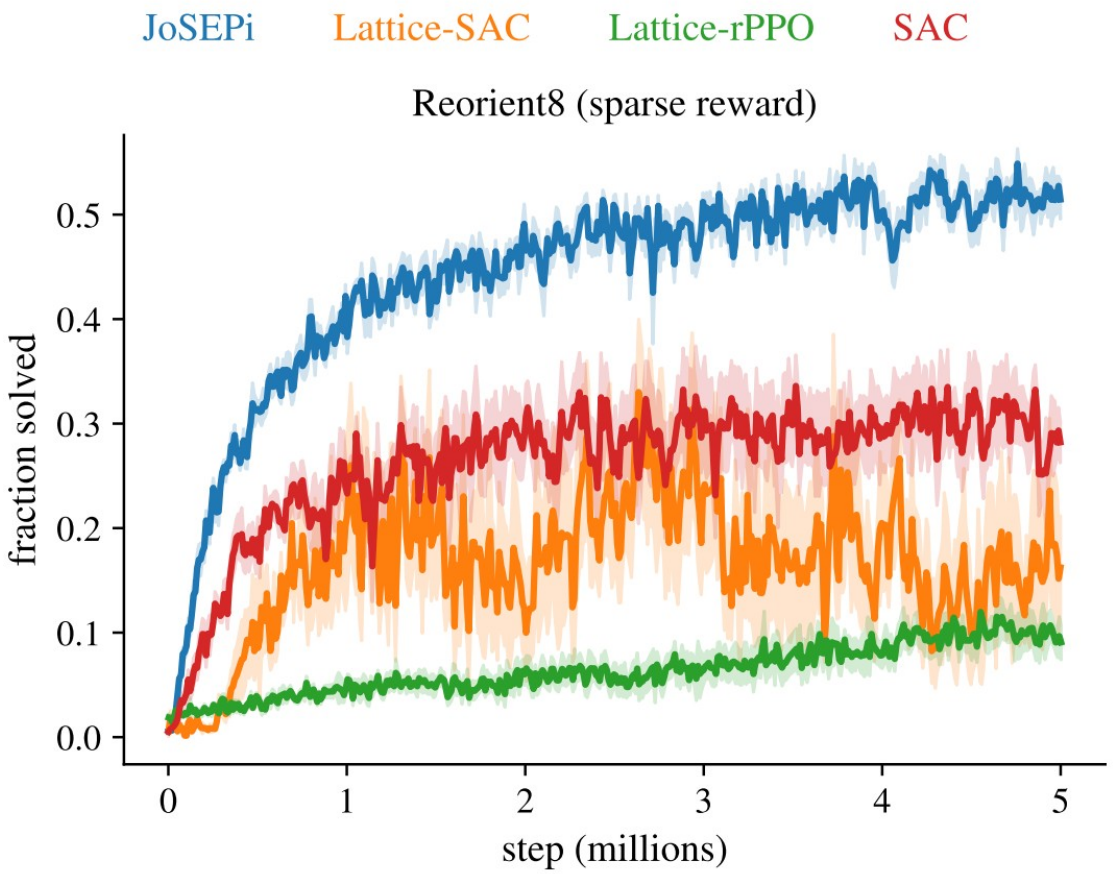
结论：部分基线最终接近，但 JoSEPi 收敛约快 2–3 倍。

转笔



结论：多指接触切换任务中，最终达标步数占比更高。

稀疏奖励下的动作子空间学习



Heald et al., 2026 • Fig. 5

检验问题

奖励稀疏时，状态转移数据仍能支持动作子空间学习吗?

实验设置

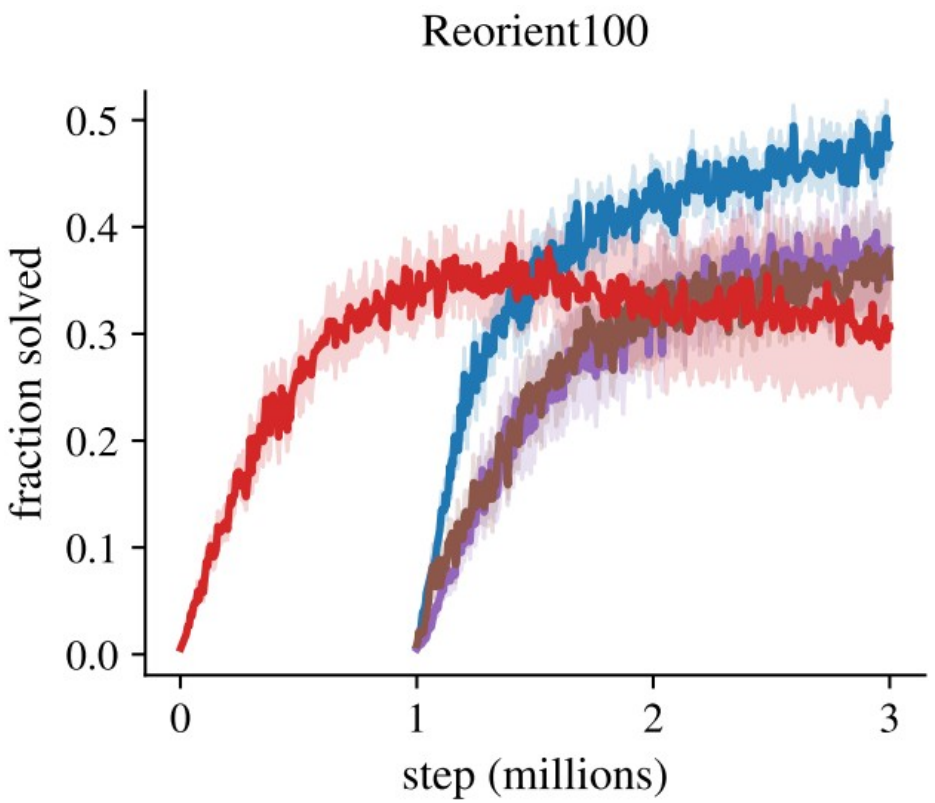
Reorient8：达标时奖励 1，其余为 0；全部交互数据用于训练动力学模型

实验结论

仍优于基线：即使奖励稀疏，每次交互仍提供动力学监督信号。

预学习动作子空间后迁移到新任务

JoSEPi SAR SD-SAR SAC



检验问题

固定预学习的动作子空间后，能否高效学习新任务?

实验设置

Reorient8： 100 万步探索数据
Reorient100： 固定子空间后训练

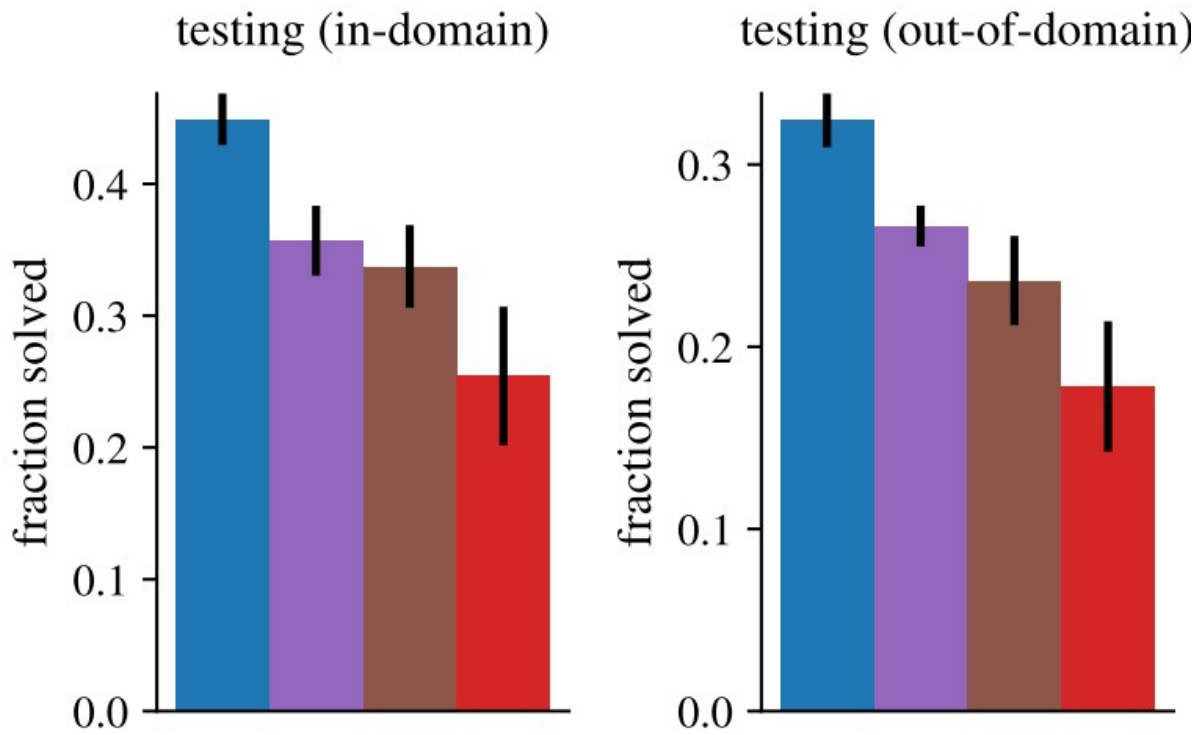
关键对照： SD-SAR

结论： JoSEPi 优于 SD-SAR；按关节运动响应构造子空间，比只重构肌肉激活更利于迁移。

Fig. 6 · 横轴计入 100 万步探索数据采集成本

未见物体：域内与域外泛化

JoSEPi SAR SD-SAR SAC



检验问题

训练后的策略能否零样本操作未见过的物体?

实验设置

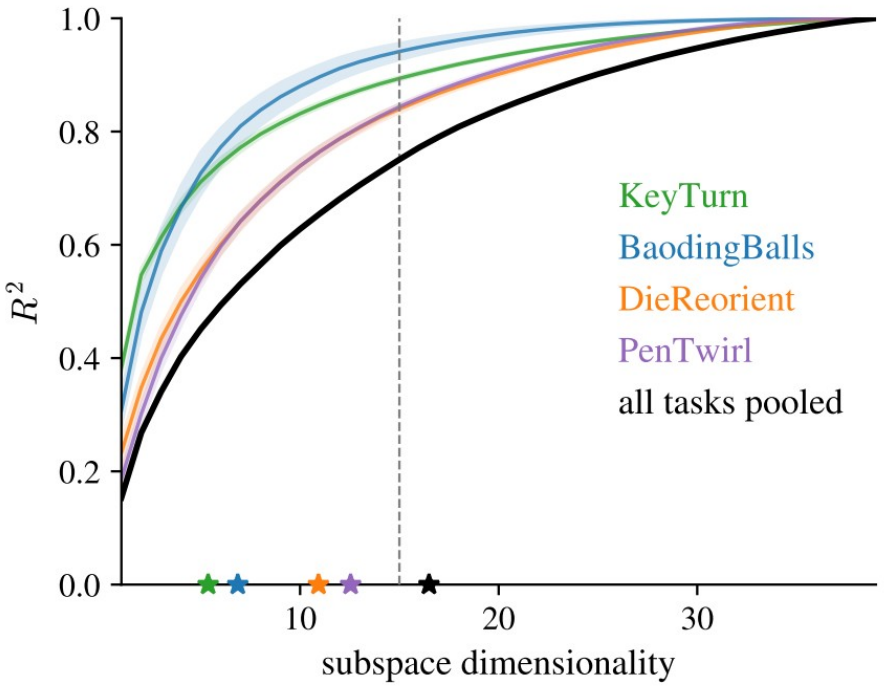
在 Reorient100 上训练，再以未见的域内和域外几何配置评估

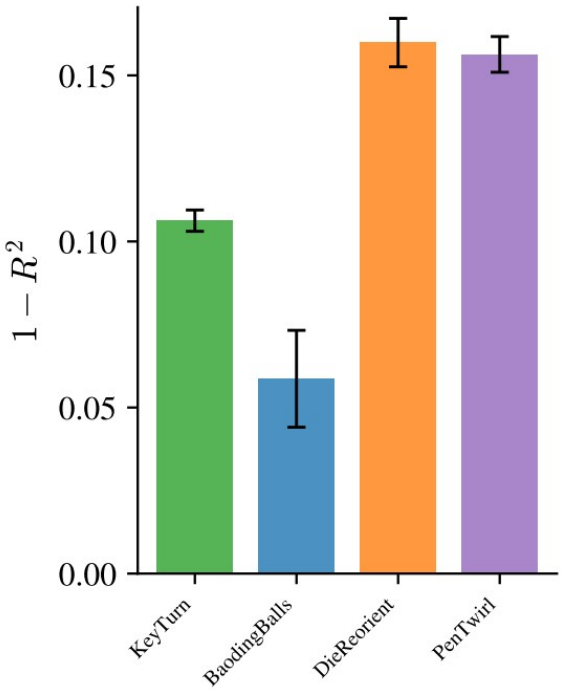
实验结论

两组未见物体上均优于基线，支持对几何变化的一定泛化能力。

Heald et al., 2026 • Fig. 6, centre/right

局部低维动作空间与全局肌肉激活维数





每个状态： 15 维潜在动作

策略使用随状态变化的 15 维动作子空间

跨状态肌肉激活数据

15 个 PCA 主成分不足以重建全部跨状态的激活变化

局部与全局

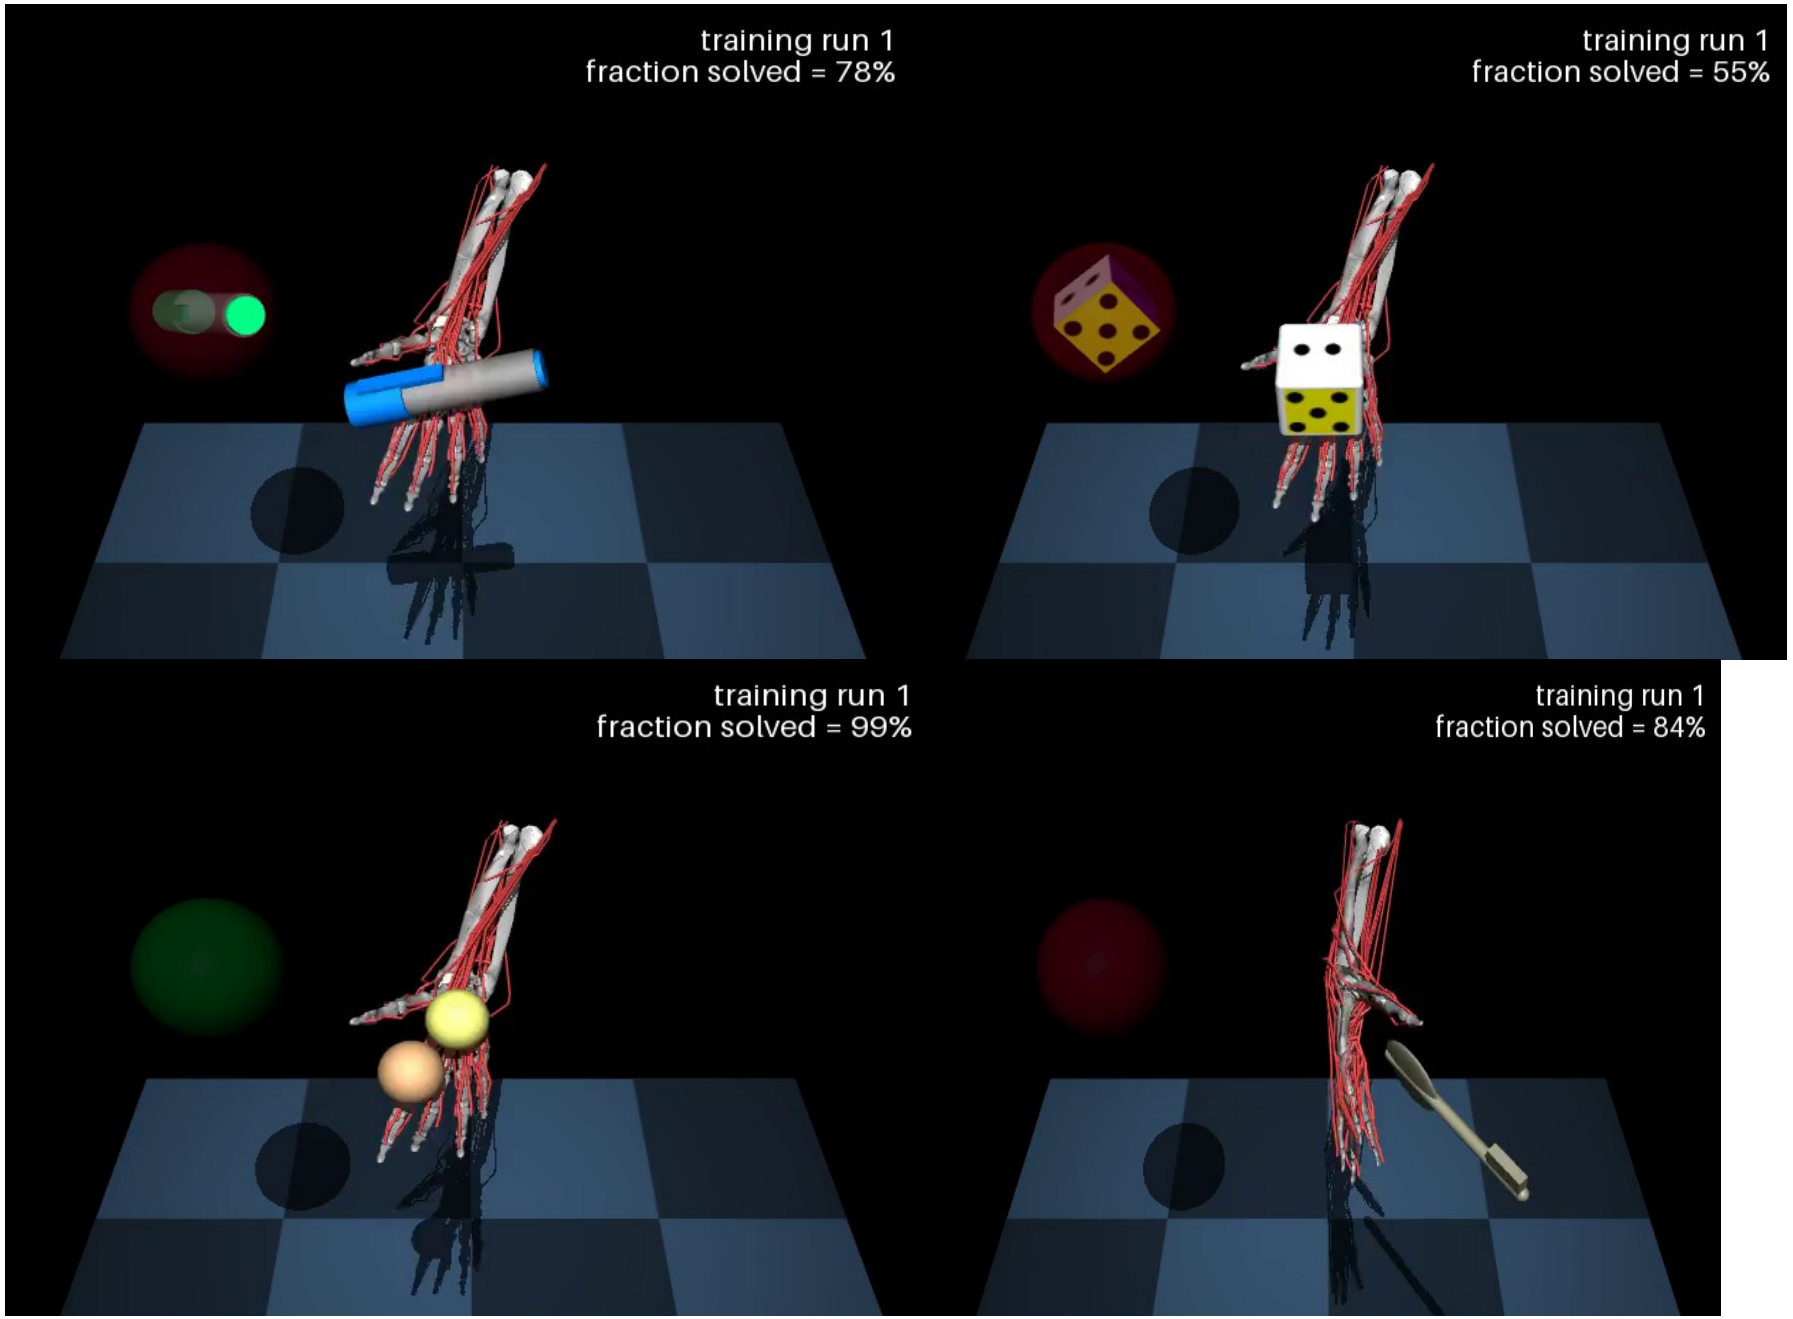
局部控制虽为 15 维，跨状态激活仍可呈现更高维结构。

Heald et al., 2026 • Appendix Fig. 10

浙江大学 ZHEJIANG UNIVERSITY

JoSE： 主要共享

JoSE 提出了一种以关节运动可控性为依据、具有**信息论理论支撑**的状态依赖**肌肉协同**构造方法，并通过动力学学习与强化学习相结合，实现了高维冗余肌肉系统的高效灵巧控制。


training run 1
fraction solved = 78%
training run 1
fraction solved = 55%
training run 1
fraction solved = 99%
training run 1
fraction solved = 84%